Previsão da Probabilidade de AVC

Eduarda Correia[1[2024137787]], Lara Veríssimo[1[2024145138]] e Prof. Doutora Dora Melo[1]

[1] Universidade Politécnica de Coimbra, Coimbra Business School | ISCAC

Resumo. O Acidente Vascular Cerebral (AVC) constitui uma das principais causas de mortalidade e incapacidade a nível mundial, reforçando a necessidade de ferramentas que apoiem a sua deteção precoce. Neste estudo, recorre-se ao *Stroke Prediction Dataset*, disponível no Kaggle, com o objetivo de analisar fatores demográficos, clínicos e comportamentais associados ao risco de AVC e desenvolver modelos preditivos baseados em aprendizagem automática. O trabalho segue integralmente a metodologia CRISP-DM, contemplando as fases de compreensão, preparação, análise exploratória, modelação e avaliação.

A análise exploratória permitiu identificar relações significativas entre variáveis como idade, hipertensão, doença cardíaca, nível médio de glicose e hábitos tabágicos. Foram testados três algoritmos, o Random Forest, a Regressão Logística e o Naive Bayes, de forma a comparar o seu desempenho na previsão da ocorrência de AVC. Apesar da elevada exatidão global obtida pelos modelos, verificou-se que o acentuado desequilíbrio do conjunto de dados afetou negativamente a capacidade de identificar casos positivos O Naive Bayes destacou-se por apresentar a melhor capacidade de identificar casos positivos de AVC, graças à sua sensibilidade superior, apesar de não ser o modelo com maior exatidão global. Já o Random Forest e a Regressão Logística obtiveram valores elevados de exatidão global, mas mostraram dificuldades acrescidas na identificação da classe minoritária devido ao forte desequilíbrio do conjunto de dados. Os resultados demonstram o potencial da inteligência artificial como apoio à saúde pública, permitindo a identificação de grupos de risco e contribuindo para estratégias de prevenção mais eficazes. Contudo, evidenciam também a necessidade de dados mais equilibrados e completos para o aperfeiçoamento dos modelos preditivos.

Palavras-chave: AVC, Inteligência Artificial, Machine Learning, Modelos Preditivos, Fatores de Risco, Saúde Pública.

1 Introdução

As doenças cerebrovasculares, em particular o Acidente Vascular Cerebral (AVC), constituem uma das principais causas mundiais de morte e de incapacidade permanente, representando um considerável encargo para a saúde pública e os sistemas de cuidados médicos. Este panorama evidencia a necessidade urgente de estratégias eficazes de prevenção, onde se destaca a identificação precoce de indivíduos com risco elevado.

O presente estudo propõe a utilização do conjunto de dados "Stroke Prediction Dataset", disponibilizado na plataforma Kaggle, o qual reúne informações demográficas e clínicas, tais como idade, género, presença de hipertensão, nível de glicose, índice de

massa corporal (IMC) e hábitos de vida associados à variável-alvo "sofreu AVC ou não". Com base neste conjunto, o objetivo central é desenvolver e validar um modelo que estime a probabilidade de ocorrência de AVC, incluindo tanto a fase de preparação e limpeza dos dados como a de modelação e avaliação de algoritmos de aprendizagem.

Ao combinar a análise de fatores de risco tradicionais com abordagens de IA, procura-se compreender melhor os determinantes da ocorrência de AVC e, simultaneamente, evidenciar o valor da inteligência artificial como ferramenta de apoio à saúde pública. Em última instância, o trabalho visa contribuir para estratégias de prevenção e deteção precoce, com possíveis implicações práticas para a redução da incidência e do impacto dos AVCs na sociedade.

2 Trabalhos relacionados

Para a realização deste estudo, foram consultados diversos trabalhos científicos que abordam a previsão de Acidentes Vasculares Cerebrais (AVC) através de métodos de análise de dados e aprendizagem automática.
- Previsão de AVC com recurso a inteligência artificial (Singh & Choudhary, 2017)
- Análise do desempenho da previsão de AVC recorrendo a algoritmos de classificação de aprendizagem automática (Sailasya & Kumari, 2021)

A previsão de Acidentes Vasculares Cerebrais (AVC) tem recebido crescente atenção na literatura científica, sobretudo devido ao potencial da aprendizagem automática para apoiar o diagnóstico precoce e a gestão do risco clínico. Singh & Choudhary (2017) exploraram técnicas de inteligência artificial na identificação de padrões associados ao AVC, demonstrando que métodos supervisionados podem contribuir para melhorar a deteção de fatores de risco. O seu estudo salientou a utilidade de modelos como árvores de decisão e redes neuronais na análise de dados clínicos, embora limitado pela reduzida dimensão e representatividade do conjunto de dados utilizado.

Sailasya & Kumari (2021) realizaram uma análise comparativa entre diversos algoritmos de classificação aplicados à previsão de AVC, incluindo Regressão Logística, Support Vector Machines, Random Forest e K-Nearest Neighbors. As autoras concluíram que o desempenho dos modelos depende fortemente das características do conjunto de dados, em particular da presença de desequilíbrio entre classes. Este aspeto influencia de forma significativa a capacidade dos algoritmos identificarem casos positivos, levando as investigadoras a defenderem a necessidade de métricas adequadas e de estratégias de pré-processamento específicas.

Os estudos existentes apontam para o potencial da inteligência artificial na melhoria dos processos de previsão e triagem de AVC, embora evidenciem desafios associados à qualidade dos dados, à variabilidade das populações analisadas e à escassez de informação clínica detalhada. O presente trabalho enquadra-se nesta linha de investigação ao comparar diferentes algoritmos num conjunto de dados amplamente utilizado, avaliando a forma como estes respondem à presença de desequilíbrio das classes e às múltiplas variáveis associadas ao risco de AVC.

3 Metodologia e Compreensão dos Dados

O presente estudo segue a metodologia CRISP-DM (Cross Industry Standard Process for Data Mining), que compreende várias fases desde a compreensão dos dados até à sua modelação e interpretação. Nesta secção são descritas as etapas correspondentes às fases de Compreensão dos Dados (Data Understanding) e Preparação dos Dados (Data Preparation), fundamentais para assegurar a qualidade e coerência da análise posterior.

3.1 Fonte de Dados

O conjunto de dados utilizado neste estudo foi obtido da plataforma Kaggle, no dataset intitulado *"Healthcare Dataset — Stroke Data"*. Trata-se de uma base de dados aberta, extensamente utilizada para estudos relacionados com a previsão de AVC (Acidente Vascular Cerebral). (Palacios, 2021)
O conjunto de dados contém registos de pacientes com diversas características clínicas e demográficas, recolhidos de fontes hospitalares e de inquéritos de saúde. O objetivo é possibilitar a construção de modelos preditivos que estimem a probabilidade de ocorrência de AVC com base nos fatores de risco.

3.2 Descrição dos Dados

Nome do Atributo	Tipo de Dados	Descrição	Domínio / Intervalo
id	Quantitativo (inteiro)	Identificador único do paciente	Numérico
gender	Qualitativo nominal	Género biológico	{Male, Female, Other}
age	Quantitativo contínuo	Idade do paciente	0 – 82 anos
hypertension	Qualitativo binário	Presença de hipertensão	{0 = não, 1 = sim}
heart_disease	Qualitativo binário	Presença de doença cardíaca	{0 = não, 1 = sim}

ever_married	Qualitativo binário	Estado civil	{Yes, No}
work_type	Qualitativo nominal	Tipo de ocupação	{Private, Self-employed, Govt_job, Children, Never_worked}
Residence_type	Qualitativo nominal	Tipo de residência	{Urban, Rural}
avg_glucose_level	Quantitativo contínuo	Média do nível de glicose no sangue	~55 – 270 mg/dL
bmi	Quantitativo contínuo	Índice de Massa Corporal	~10 – 97
smoking_status	Qualitativo nominal	Hábito de fumar	{formerly smoked, never smoked, smokes, Unknown}
stroke	Qualitativo binário	Indicador de ocorrência de AVC	{0 = não, 1 = sim}

Tabela 1. Descrição dos Atributos do Conjunto de Dados
Fonte: Elaboração própria

O conjunto de dados é composto por 5110 registos (linhas) e 12 atributos.
Na tabela 1, estão presentes quatro colunas que detalham as características dos atributos utilizados para a análise da ocorrência de AVC. É possível encontrar o nome de cada atributo de estudo na primeira coluna (id, gender, age, hypertension, heart_disease, ever_married, work_type, Residence_type, avg_glucose_level, bmi, smoking_status e stroke), que representam informações demográficas, clínicas e comportamentais dos pacientes.
Na segunda coluna conseguimos identificar a relação entre o tipo de dados e cada atributo, diferenciando as variáveis quantitativas (inteiras ou contínuas) e qualitativas (nominais ou binárias). A terceira coluna representa a função e relevância de cada atributo no contexto da análise, como a identificação de fatores de risco (idade, hipertensão, doenças cardíacas, hábitos tabágicos e níveis de glicose) que podem influenciar a probabilidade de AVC. Por último, a quarta coluna apresenta o domínio ou intervalo de valores possíveis para cada variável, identificando as categorias ou os limites numéricos registados no conjunto de dados.

3.3 Análise Exploratória dos Dados

3.3.1 Seleção e compreensão dos dados

Numa fase inicial, foi efetuada uma análise detalhada do conjunto de dados com o propósito de avaliar a sua estrutura e identificar possíveis problemas de qualidade.

Analisou-se o formato das variáveis e a consistência das categorias nas variáveis qualitativas, como género, estado civil e tipo de trabalho, garantindo que não existiam erros ou discrepâncias. Este processo foi essencial para assegurar que o conjunto de dados estava limpo e adequado para as etapas seguintes de exploração e modelação dos dados.

3.3.2 Estatísticas Descritivas

Estatística	**Age** (Idade)	**avg_glucose_level** (Glucose)	**BMI** (Índice de Massa Corporal)
Média	43,22661448	106,1476771	28,89
Mediana	45	91,885	28,10
Mínimo	0,08	55,12	10,30
Máximo	82	271,74	97,60
Desvio padrão	22,61264672	45,28356015	7,85406673
Contagem (valores válidos)	5110	5110	4909
Valores em falta (nulos)	0	0	201

Tabela 2. Estatísticas descritivas das principais variáveis numéricas do conjunto de dados
Fonte: Elaboração própria

Durante a análise exploratória, observou-se a presença de registos com idade entre 0 e 1.
Considerou-se que estes valores podem corresponder a indivíduos com menos de dois anos de idade, pelo que foram mantidos no conjunto de dados.
Com base na observação dos dados, verificou-se que os valores de glicose e de índice de massa corporal apresentam grande variação, refletindo a diversidade do perfil clínico da amostra. Foram também elaborados gráficos de dispersão e histogramas que permitiram identificar distribuições assimétricas e a presença de outliers em algumas variáveis.

3.3.3 Relações entre variáveis

Foram calculadas as correlações de Pearson entre as principais variáveis clínicas do conjunto de dados.
Esta etapa permite compreender de que forma fatores como a idade, a hipertensão, a doença cardíaca, o nível médio de glicose e o índice de massa corporal (IMC) se relacionam entre si e com a variável dependente stroke (ocorrência de AVC).

A correlação de Pearson foi o método utilizado, uma vez que permite medir a força e a direção da relação linear entre variáveis numéricas.
Nos casos em que as variáveis são binárias, como a hipertensão, a doença cardíaca e o AVC, a correlação representa uma forma de correlação bisserial pontual, adequada para este tipo de dados, amplamente utilizada para avaliar a relação entre uma variável contínua e uma variável dicotómica, permitindo identificar tendências e diferenças médias entre os dois grupos. (Lima, 2021)

	Idade	*Hipertensão*	*Doença Cardíaca*	*Nível de Glucose*	*IMC*	*AVC*
Idade	1					
Hipertensão	0,2764	1				
Doença Cardíaca	0,2638	0,1083	1			
Nível de Glucose	0,2382	0,1745	0,1619	1		
IMC	0,3334	0,1678	0,0414	0,1755	1	
AVC	0,2453	0,1279	0,1349	0,1319	0,0424	1

Tabela 3. Correlação entre Variáveis Numéricas e Ocorrência de AVC
Fonte: Elaboração própria

A idade apresentou correlação positiva com quase todas as restantes variáveis clínicas, especialmente com a hipertensão ($r \approx 0,28$) e a doença cardíaca ($r \approx 0,26$), o que demonstra que estas condições tendem a aumentar com o avançar da idade. A correlação entre idade e AVC ($r = 0,25$) foi uma das mais elevadas, confirmando que o envelhecimento é um dos fatores mais determinantes para a ocorrência deste evento.

A hipertensão mostrou uma correlação positiva com a doença cardíaca ($r \approx 0,11$) e com o nível médio de glicose ($r \approx 0,17$), indicando que estas condições frequentemente coexistem. Além disso, verificou-se uma correlação positiva com o AVC ($r = 0,13$), sugerindo que indivíduos hipertensos apresentam maior probabilidade de sofrer um acidente vascular cerebral.

A doença cardíaca também revelou correlações positivas com a idade, hipertensão e glicose, além de uma relação significativa com o AVC ($r = 0,13$), o que confirma a influência das patologias cardiovasculares no risco de AVC.

O nível médio de glicose apresentou correlação moderada com a idade ($r = 0,24$) e fraca com o IMC ($r = 0,17$). A sua relação com o AVC ($r = 0,13$) foi positiva, indicando que níveis mais elevados de glicose podem contribuir para o aumento do risco, ainda que de forma menos expressiva.

O IMC mostrou uma correlação moderada com a idade ($r = 0,32$), mas fraca com o AVC ($r = 0,04$), demonstrando que o peso corporal, isoladamente, não tem uma influência significativa na ocorrência de AVC neste conjunto de dados.

Por fim, a variável AVC ("stroke") apresentou correlação positiva com todas as restantes, sendo a idade o fator mais associado, seguida pela doença cardíaca, hipertensão e nível de glicose, enquanto o IMC se mostrou praticamente neutro.
Para aprofundar a compreensão das ligações entre as variáveis do conjunto de dados, foram elaborados gráficos e tabelas que ilustram as relações entre as variáveis numéricas e a ocorrência de AVC.
Estas visualizações complementam a análise estatística das correlações, permitindo observar tendências, padrões e possíveis associações entre fatores como a idade, o nível médio de glicose, o índice de massa corporal e a variável-alvo "stroke".

Rótulos de Linha	Média de stroke
Não tem doença cardíaca (0)	4,18%
Tem doença cardíaca (1)	17,03%
Total Geral	**4,87%**

Tabela 4. Relação entre doença cardíaca e ocorrência de AVC
Fonte: Elaboração própria

A tabela apresenta a média de ocorrência de AVC (stroke) entre pessoas com e sem doença cardíaca. Nota-se que indivíduos sem doença cardíaca têm uma média de 4,18% de AVC, enquanto aqueles com doença cardíaca apresentam uma média significativamente mais alta, de 17,03%. No total geral, a média é de 4,87%. Estes dados indicam que a presença de doença cardíaca está fortemente associada a um aumento no risco de AVC, evidenciando a importância do controlo e acompanhamento dessas condições.

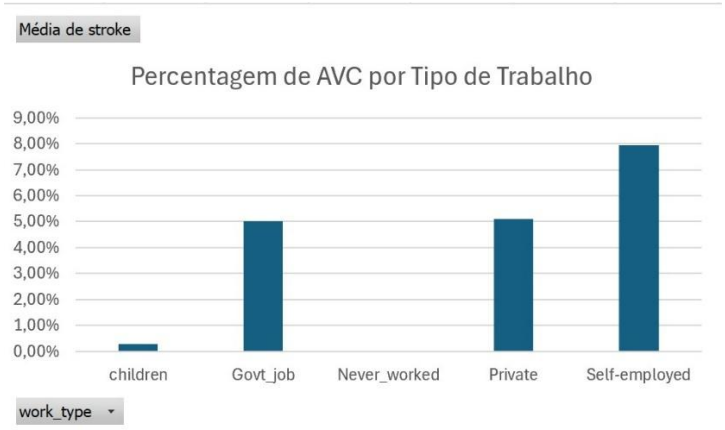


Gráfico 1. Percentagem média de casos de AVC em função do tipo de trabalho.
Fonte: Elaboração própria

Neste gráfico observa-se que indivíduos autónomos (self-employed) apresentam a maior prevalência de AVC (aprox. 7,9%), seguidos por trabalhadores do setor público e privado (~5%).
O grupo children apresenta valores residualmente baixos, conforme esperado.

O grupo never_worked apresenta taxa nula, embora a dimensão reduzida da amostra neste segmento possa limitar a interpretação.
Estes resultados sugerem que fatores socioeconómicos e ocupacionais podem influenciar o risco de AVC, possivelmente associados a diferenças no estilo de vida, stress laboral ou acesso a cuidados de saúde.

gender	Média de stroke
Female	4,7%
Male	5,1%
Other	0,0%

Tabela 5. Relação entre o género e a ocorrência de AVC
Fonte: Elaboração própria

Nesta tabela é possível identificar que a incidência de AVC é ligeiramente superior no sexo masculino (5,1%) em comparação com o feminino (4,7%). O grupo "Other" apresenta valor nulo, o que pode estar associado à reduzida representatividade desta categoria no conjunto de dados. Embora a diferença entre géneros seja pequena, os resultados estão alinhados com estudos epidemiológicos que indicam tendência ligeiramente maior no sexo masculino em determinadas faixas etárias.

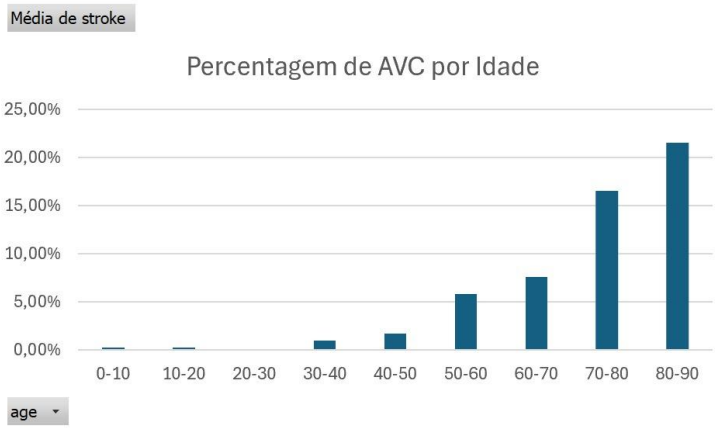


Gráfico 2. Percentagem média de casos de AVC em função da idade
Fonte: Elaboração própria

A análise da variável idade revelou uma relação positiva clara com a ocorrência de AVC. Observa-se que a percentagem de casos de AVC aumenta progressivamente com o avançar da idade, sendo praticamente nula em idades inferiores a 30 anos e ultrapassando 20% nos indivíduos com mais de 80 anos.

Este comportamento confirma que a idade é um dos principais fatores de risco para a ocorrência de AVC, em concordância com a literatura médica.

Rótulos de Linha	Média de stroke
Não tem hipertensão (0)	3,97%
Tem hipertensão (1)	13,25%
Total Geral	**4,87%**

Tabela 6. Relação entre hipertensão e a ocorrência de AVC
Fonte: Elaboração própria

A tabela apresenta a média de ocorrência de acidente vascular cerebral (stroke) entre pessoas com e sem hipertensão. Observa-se que indivíduos sem hipertensão têm uma média de ocorrência de 3,97%, enquanto aqueles com hipertensão apresentam uma média bem mais elevada, de 13,25%. No total geral da amostra, a média de ocorrência de stroke é de 4,87%. Estes dados revelam que a presença de hipertensão está associada a um maior risco de AVC.

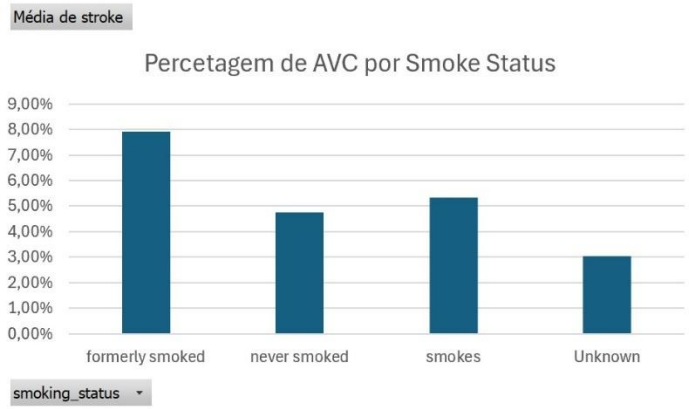


Gráfico 3. Percentagem média de casos de AVC em função do hábito tabágico
Fonte: Elaboração própria

O gráfico mostra a percentagem de AVC (acidente vascular cerebral) de acordo com o status de tabagismo dos indivíduos. Observa-se que pessoas que fumaram anteriormente (formerly smoked) apresentam a maior taxa de AVC, cerca de 8%. Em seguida, vêm os que ainda fumam (smokes), com aproximadamente 6%. Já os que nunca fumaram (never smoked) têm uma taxa menor, por volta de 5%, e o grupo com estatuto desconhecido (unknown) apresenta uma menor percentagem, cerca de 3%. Esteess resultados sugerem que o hábito de fumar, mesmo no passado, está associado a um risco mais elevado de AVC em comparação com quem nunca fumou.

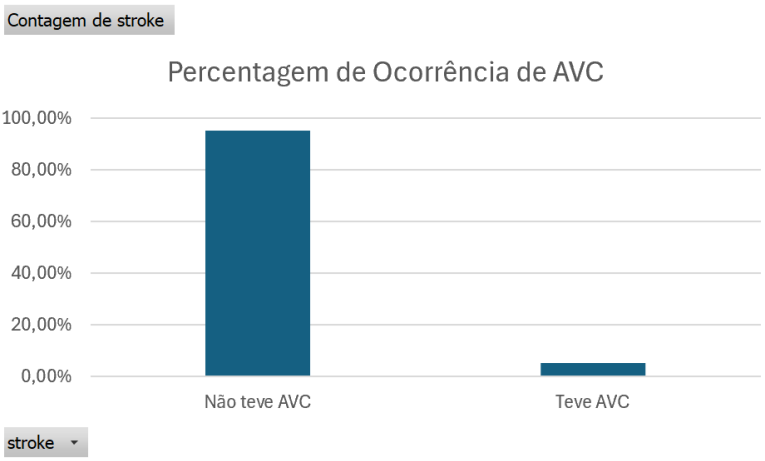


Gráfico 4. Percentagem da ocorrência de AVC
Fonte: Elaboração própria

A análise da variável de desfecho revela que 95,13% dos indivíduos da amostra não apresentaram AVC, enquanto apenas 4,87% tiveram historial da condição.
Esta distribuição evidencia uma baixa prevalência de AVC na população estudada, o que está em conformidade com a incidência deste tipo de evento na população geral. No entanto, observa-se um desequilíbrio significativo entre as classes, indicando que o conjunto de dados é fortemente desequilibrado.
Este aspeto é particularmente relevante para as etapas subsequentes de análise estatística e modelação preditiva, uma vez que muitos algoritmos de machine learning tendem a favorecer a classe maioritária. Assim, será fundamental considerar estratégias de balanceamento e métricas de avaliação específicas, de forma a garantir uma avaliação justa e rigorosa do desempenho dos modelos.

3.4 Processamento dos Dados

3.4.1 Limpeza dos dados

O conjunto de dados analisado é composto por 5110 registos e 12 atributos. Após a verificação de consistência, não foram identificados valores duplicados, confirmando a integridade estrutural do ficheiro.

A variável “bmi” apresentou 201 valores em falta (NaN), correspondentes a casos em que o índice de massa corporal não foi registado. Estes valores foram tratados através da substituição pela média da variável, de modo a preservar a dimensão da amostra e evitar perda de informação.

Durante a fase de limpeza dos dados, observou-se que a variável “age” apresentava 22 registos com valores decimais. Considerou-se que estes casos poderiam corresponder a bebés com menos de dois anos de idade, registados de forma decimal. Assim, decidiu-

se manter estes valores no conjunto de dados, uma vez que representam uma faixa etária plausível dentro do contexto clínico e contribuem para a representatividade total da amostra.

As variáveis categóricas como “gender”, “work_type” e “Residence_type” foram inspecionadas quanto à presença de categorias inconsistentes. Foi identificada a categoria “Other” na variável “gender”, que, embora pouco frequente, foi mantida por representar uma possível realidade demográfica.

4 Modelação

Na fase de modelação, o objetivo principal foi desenvolver sistemas preditivos baseados em algoritmos de machine learning capazes de estimar a probabilidade de ocorrência de Acidente Vascular Cerebral (AVC). Utilizando o conjunto de dados clínicos e demográficos disponibilizado, foram construídos modelos que analisam fatores de risco como idade, hipertensão, doenças cardíacas, o tipo de atividade profissional, níveis de glicose e estado tabágico. Esta abordagem permite identificar padrões relevantes associados ao risco de AVC, contribuindo para a deteção precoce, apoio ao diagnóstico e desenvolvimento de estratégias preventivas mais eficazes, sustentadas por técnicas avançadas de inteligência artificial.

4.1 Algoritmos Utilizados

Para o desenvolvimento deste estudo, foram utilizados três algoritmos de machine learning: Random Forest, Regressão Logística e NaiveBayes. Cada um destes modelos foi selecionado com o objetivo de explorar diferentes abordagens preditivas e comparar o seu desempenho na estimativa do risco de Acidente Vascular Cerebral (AVC).

- Random Forest

O Random Forest é um algoritmo de aprendizagem supervisionada que combina múltiplas árvores de decisão com o intuito melhorar a precisão e a robustez do modelo. Cada árvore é treinada sobre uma amostra diferente do conjunto de dados e utiliza subconjuntos aleatórios de variáveis, o que reduz o risco de overfitting e aumenta a capacidade de generalização. (Breiman, 2001)

- Regressão Logística

A Regressão Logística é um dos métodos estatísticos mais utilizados na área da saúde para modelar eventos binários, como a ocorrência ou não de uma doença. Trata-se de um algoritmo de classificação que estima a probabilidade de um determinado resultado ocorrer com base em variáveis explicativas, permitindo não apenas prever a classe final, mas também interpretar o contributo de cada variável no resultado.

- Naive Bayes

Os modelos Naive Bayes são classificadores probabilísticos baseados no Teorema de Bayes, assentando na suposição de independência condicional entre os atributos. Esta simplificação torna o método particularmente fácil de implementar, uma vez que não exige processos iterativos complexos para estimar os parâmetros do modelo.
Devido a estas características, o Naive Bayes é amplamente utilizado em áreas como a ciência médica, nomeadamente em tarefas de diagnóstico e previsão de doenças. Apesar da sua natureza simples, este algoritmo demonstra frequentemente um desempenho competitivo, superando, em alguns casos, métodos de classificação mais sofisticados.

Random Forest

```
=== Classifier model (full training set) ===

RandomForest

=== Summary ===

Correctly Classified Instances        4817               94.2661 %
Incorrectly Classified Instances       293                5.7339 %
Kappa statistic                          0.0449
Mean absolute error                      0.0849
Root mean squared error                  0.2224
Relative absolute error                 91.4533 %
Root relative squared error            103.2991 %
Total Number of Instances             5110

=== Detailed Accuracy By Class ===

               TP Rate  FP Rate  Precision  Recall  F-Measure  MCC      ROC Area  PRC Area  Class
               0,989    0,960    0,953      0,989   0,970      0,056    0,778     0,983     0
               0,040    0,011    0,156      0,040   0,064      0,056    0,778     0,128     1
Weighted Avg.  0,943    0,914    0,914      0,943   0,926      0,056    0,778     0,941

=== Confusion Matrix ===

   a    b   <-- classified as
 4807   54 |    a = 0
  239   10 |    b = 1
```

A aplicação do Random Forest com seis variáveis (age, hypertension, heart_disease, work_type, avg_glucose_level e smoking_status) resultou num desempenho estável na classificação do risco de AVC. O modelo obteve uma exatidão global de 94.27%, classificando corretamente a maioria dos casos da classe negativa (stroke = 0), que representa a classe dominante no dataset.

A matriz de confusão evidencia que o modelo apresenta excelente desempenho na classe negativa (stroke = 0), classificando corretamente 4807 indivíduos sem AVC. No entanto, a deteção de casos da classe positiva revelou-se limitada, com apenas 10 verdadeiros positivos. Este resultado era esperado, dada a forte assimetria do dataset, onde a classe positiva representa uma proporção muito reduzida das observações. Assim, o modelo tende a privilegiar a classe maioritária, o que impacta negativamente a sensibilidade relativamente à classe AVC.

Regressão Logística

```
=== Summary ===

Correctly Classified Instances        4862               95.1468 %
Incorrectly Classified Instances       248                4.8532 %
Kappa statistic                          0.0076
Mean absolute error                      0.0839
Root mean squared error                  0.2061
Relative absolute error                 90.3497 %
Root relative squared error             95.7223 %
Total Number of Instances             5110

=== Detailed Accuracy By Class ===

               TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
               1,000    0,996    0,951      1,000    0,975      0,062    0,839     0,989     0
               0,004    0,000    1,000      0,004    0,008      0,062    0,839     0,188     1
Weighted Avg.  0,951    0,947    0,954      0,951    0,928      0,062    0,839     0,950

=== Confusion Matrix ===

   a    b   <-- classified as
 4861    0 |    a = 0
  248    1 |    b = 1
```

A aplicação da Regressão Logística apresentou uma exatidão global de 95.15%, classificando corretamente a grande maioria dos indivíduos da classe negativa (stroke = 0), que continua a representar quase todo o dataset. O modelo mostrou-se extremamente eficaz nesta classe, tendo acertado praticamente todos os casos sem AVC, o que se verifica pelos 4861 acertos registados na matriz de confusão.

Contudo, o modelo revelou dificuldades na identificação de casos positivos de AVC. Entre os 249 indivíduos que sofreram AVC, apenas 1 foi corretamente identificado, enquanto os restantes foram classificados como “não AVC”. Este resultado é esperado devido ao forte desbalanceamento do dataset, onde os casos de AVC são muito raros.

Naive Bayes

```
=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances        4589               89.8043 %
Incorrectly Classified Instances       521               10.1957 %
Kappa statistic                          0.1752
Mean absolute error                      0.1218
Root mean squared error                  0.2747
Relative absolute error                131.1105 %
Root relative squared error            127.6003 %
Total Number of Instances             5110

=== Detailed Accuracy By Class ===

               TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
               0,928    0,695    0,963      0,928    0,945      0,182    0,825     0,988     0
               0,305    0,072    0,179      0,305    0,226      0,182    0,825     0,172     1
Weighted Avg.  0,898    0,664    0,925      0,898    0,910      0,182    0,825     0,948

=== Confusion Matrix ===

   a    b   <-- classified as
 4513  348 |    a = 0
  173   76 |    b = 1
```

O relatório avalia o desempenho do modelo Naive Bayes aplicado a 5110 instâncias, tendo obtido uma exatidão de 89,80% e uma taxa de erro de 10,20%. A estatística kappa foi de 0,1752, indicando um nível de concordância baixo, influenciado sobretudo pelo desbalanceamento entre classes. O erro absoluto médio registado foi 0,1218, enquanto a raiz do erro quadrático médio se fixou em 0,2747, refletindo um desempenho global moderado.

Para a classe 0 (sem AVC), o modelo apresentou bons resultados, com taxa de verdadeiros positivos de 92,8%, precisão de 96,3% e uma área sob a curva ROC de 0,825, demonstrando capacidade satisfatória para identificar corretamente indivíduos que não sofreram AVC.

Já para a classe 1 (AVC), o desempenho foi inferior. O modelo obteve uma taxa de verdadeiros positivos de 30,5% e uma precisão de 17,9%, revelando maior dificuldade na deteção correta de casos positivos. A matriz de confusão confirma este comportamento, mostrando que a maioria dos erros ocorreu na classificação de instâncias reais da classe 1 como pertencentes à classe 0. No total, o modelo identificou

corretamente 76 casos de AVC, enquanto 173 casos foram incorretamente classificados como não AVC.
De forma geral, o Naive Bayes demonstrou um desempenho mais equilibrado entre as duas classes do que os restantes modelos testados, destacando-se pela sua capacidade relativamente superior de identificar casos de AVC, apesar da menor exatidão global.

Modelo	Exatidão (%)	Precisão	Recall	F1-Score
Random Forest	94,27%	0,914	0,943	0,928
Regressão Logística	95,15%	0,954	0,951	0,928
Naive Bayes	89,80%	0,925	0,898	0,910

Tabela 7. Comparação do desempenho dos modelos de classificação na previsão de AVC, com base nas métricas de exatidão, precisão, recall e F1-Score
Fonte: Elaboração própria

A avaliação dos modelos permitiu comparar o desempenho global do Random Forest, da Regressão Logística e do Naive Bayes. A Regressão Logística apresentou a exatidão global mais elevada, enquanto o Random Forest evidenciou um desempenho estável com métricas equilibradas de precisão, recall e F1-Score para a classe maioritária. O Naive Bayes, embora com exatidão inferior, destacou-se pela sua maior sensibilidade, identificando um número muito superior de casos positivos de AVC. Assim, conclui-se que cada modelo apresenta vantagens em métricas distintas, sendo o Naive Bayes o mais eficaz na deteção de AVC, enquanto a Regressão Logística e o Random Forest se revelam superiores na classificação geral.

5 Conclusão e Trabalho Futuro

A realização deste estudo permitiu avaliar criticamente o uso de modelos de aprendizagem automática na previsão de Acidentes Vasculares Cerebrais (AVC), evidenciando tanto o seu potencial como as suas limitações. Mais do que identificar quais variáveis estão associadas ao risco de AVC, o trabalho demonstrou as dificuldades inerentes à construção de modelos preditivos em contextos onde a classe de interesse é rara. A análise dos resultados permitiu concluir que o desempenho dos algoritmos é fortemente condicionado pela estrutura do conjunto de dados, em particular pelo desequilíbrio entre classes. Assim, mais do que procurar "o melhor modelo", tornou-se evidente que a qualidade dos dados e a adequação das métricas de avaliação desempenham um papel determinante na robustez das conclusões.

Apesar destas limitações, o estudo contribuiu para compreender de que forma diferentes algoritmos respondem ao mesmo problema e para reforçar a importância de metodologias de desenvolvimento estruturadas, como a CRISP-DM, no contexto da ciência de dados aplicada à saúde.

No futuro, será essencial melhorar a representatividade dos dados utilizados, quer pela recolha de informação adicional, quer pela aplicação de técnicas de balanceamento adequadas. A exploração de modelos mais avançados, nomeadamente técnicas de boosting ou redes neuronais, poderá também oferecer uma capacidade discriminativa superior. Adicionalmente, recomenda-se a construção de um protótipo de aplicação prática que permita testar o modelo em cenários reais de apoio à decisão clínica, avaliando o seu impacto potencial na triagem e prevenção do AVC.

Referências

1. Breiman, L. (2001). *Random Forests* (Vol. 45).
2. Lima, M. (2021, May 3). *Correlação bisserial pontual*. https://www.blog.psicometriaonline.com.br/o-que-e-correlacao-ponto-bisserial/
3. Palacios, F. (2021). *healthcare-dataset-stroke-data*. https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset/data
4. Sailasya, G., & Kumari, G. L. A. (2021). Analyzing the performance of stroke prediction using ML classification algorithms. *International Journal of Advanced Computer Science and Applications*, *12*(6).
5. Singh, M. S., & Choudhary, P. (2017). Stroke prediction using artificial intelligence. *2017 8th Annual Industrial Automation and Electromechanical Engineering Conference (IEMECON)*, 158–161.